

Reproductibilité en Science : Crise, Pratiques et Solutions

Synthèse de quatre articles scientifiques

Moulay Abderrahmane SIDATTY

Doctorat Informatique – 1^{ère} année

Juin 2026

FST – Université de Nouakchott

Plan de la présentation

Article 1 : Reproducibility Crisis

Article 2 : Best Practices for Scientific Computing

Article 3 : Reproducible Research in Computational Science

Article 4 : An Invitation to Reproducible Computational Research

Article 1 : Reproducibility Crisis

Constats & perception (1 576 chercheurs)

Constats

- 70% : échec à reproduire autrui
- 50% : échec sur leurs propres travaux
- 52% : crise *majeure* ; 38% : crise légère

Perception

- 73% font confiance à $\geq$ la moitié des publications
- Pas de consensus sur la définition
- Un échec $\neq$ forcément une erreur

Ampleur

- Psychologie : $\sim 40\%$ reproductible
- Biologie du cancer : $\sim 10\%$
- Communication difficile entre chercheurs

Causes & facteurs

- Pression de publication, reporting sélectif
- Mauvais design, faible puissance statistique
- Compétition, manque de temps/financement, encadrement faible

Solutions

- Meilleur design & statistiques
- Renforcement du mentorat
- Pré-enregistrement des études

Limites

- Peu d'incitations aux réplifications
- Biais vers les résultats positifs
- Coût élevé (temps + ressources)

Conclusion

- Crise réelle mais complexe
- Prise de conscience globale
- Nécessité d'un effort collectif

Article 2 : Best Practices for Scientific Computing

Constat

- Le logiciel = un instrument scientifique à part entière
- Les chercheurs y consacrent $\geq 30\%$ de leur temps
- $\geq 90\%$ sont autodidactes en programmation

Enjeu

- Erreurs de code $\rightarrow$ rétractations, corrections
- Impact amplifié par la réutilisation du code
- Objectif : code fiable, maintenable, reproductible

Bonnes pratiques (1–4)

1. Écrire pour les humains

- Fonctions courtes, noms clairs
- Style et format cohérents

2. Automatiser

- Laisser l'ordinateur répéter les tâches
- Scripts + outils de build (Make)

3. Changements incrémentaux

- Petites étapes, retours fréquents
- Gestion de versions (Git, etc.)

4. Ne pas se répéter (DRY)

- Une seule source de vérité par donnée
- Modulariser et réutiliser le code

Bonnes pratiques (5–8)

5. Anticiper les erreurs

- Assertions & tests unitaires
- Transformer les bugs en tests
- Débogueur symbolique

6. Optimiser en dernier

- D'abord un code correct, puis profiler
- Langage de haut niveau par défaut

7. Documenter le pourquoi

- Interfaces & raisons, pas l'implémentation
- Documentation intégrée au code

8. Collaborer

- Revue de code avant fusion
- Programmation en binôme
- Outil de suivi des tâches/bugs

Conclusion

- 24 recommandations, prérequis à la recherche reproductible
- Pratiques qui se renforcent mutuellement
- Adoption progressive recommandée (pas tout d'un coup)
- Gain de productivité $>$ coût d'apprentissage

Article 3 : Reproducible Research in Computational Science

Contexte

- Essor de la science computationnelle (grandes données)
- Réplication = étalon-or, mais souvent infaisable
- Trop coûteuse : climat, épidémiologie, Sloan Sky Survey

Proposition

- Reproductibilité = standard *minimal*
- Rendre données + code disponibles
- Réanalyse des mêmes données ($\neq$ réplication)
- Comble le vide entre rien et réplication complète

Le spectre de la reproductibilité

Non reproductible $\longrightarrow$ *Étalon-or*

- Publication seule (non reproductible)
- + Code
- + Code et données
- + Code et données liés et exécutables
- Réplication complète (étalon-or)

Le degré de reproductibilité dépend de ce qui est mis à disposition.

Barrières

- Code souvent indisponible
- Logiciels interactifs sans trace des actions
- Absence de culture et d'infrastructure dédiées

Exemple : revue Biostatistics

- Labels D (données), C (code), R (revu)
- 21 articles labellisés / 125, dont 5 R
- Reproductible $\neq$ correct ou valide

- **Publier le code** (peu coûteux : GitHub, SourceForge)
- Publier code nettoyé + données en format pérenne et ouvert
- Créer des dépôts communs (type PubMed Central pour code/données)
- **Conclusion** : développer une culture de la reproductibilité
- Les petits pas valent mieux que d'attendre une solution parfaite

Article 4 : An Invitation to Reproducible Computational Research

Constat

- Soutien à la politique de *Biostatistics*
- L'erreur est omniprésente en calcul scientifique
- Résultats présentés de façon trop légère

Principe (Claerbout)

- Un article = publicité , pas le travail réel
- Le vrai savoir = code + données complets
- Transparence dès le départ pour éviter les erreurs

Pourquoi travailler de façon reproductible ?

En tant que chercheur

- Meilleures habitudes de travail
- Collaboration plus efficace
- Plus d'impact : moins de concurrence, plus de citations
- Continuité : formation et reprise facilitées

En tant que citoyen/financeur

- Bonne gestion des fonds publics
- Le travail n'est pas perdu après le projet
- Accès public à un savoir public

Mise en œuvre

- À concevoir dès le début du projet
- Ex. : un script R unique générant figures et tables

Initiatives

- Numéro spécial IEEE CiSE (2009)
- Dépôt EPFL (Vetterli), GenePattern (Mesirov)

Conclusion

- Un véritable mouvement en expansion
- Objectif : atteindre une masse critique
- La reproductibilité comme composante essentielle de la publication